

Détection de fraude bancaire

Contexte et objectif

Ce projet simule un système de détection de fraude bancaire sur un dataset fortement déséquilibré (0,5 % de transactions frauduleuses, comme dans le dataset réel Credit Card Fraud Detection de Kaggle). L'objectif : comparer plusieurs stratégies de gestion du déséquilibre, choisir les bonnes métriques d'évaluation, et rendre le modèle final interprétable via SHAP.

Statistique	Valeur
Transactions	100 000 (99 500 légitimes / 500 frauduleuses)
Ratio de fraude	0,5 % (≈ 1 pour 199)
Split train / test	70 000 / 30 000 (stratifié, 30% test)




Figure 1 — Répartition des classes et distribution du montant par classe

L'accuracy est ici un indicateur trompeur : un modèle prédisant toujours "légitime" atteindrait déjà 99,5 % d'accuracy sans détecter aucune fraude. Les métriques retenues sont donc Precision, Recall, F1-score et ROC-AUC

Comparaison des stratégies de gestion du déséquilibre

Quatre approches ont été comparées sur le jeu de test : un modèle baseline sans traitement du déséquilibre, l'ajout de class_weight/sample_weight, le sur-échantillonnage SMOTE (appliqué uniquement sur le train, pour éviter toute fuite de données), et enfin l'optimisation du seuil de décision.

Stratégie	Precision	Recall	F1	ROC-AUC
Baseline (naïf)	0.986	0.967	0.976	0.997
Random Forest (class_weight)	1.000	0.800	0.889	0.9999
Gradient Boosting (sample_weight)	1.000	0.993	0.997	0.9999
Random Forest + SMOTE	1.000	0.933	0.966	0.9999
SMOTE + seuil optimisé (0.30)	0.987	0.987	0.987	0.9999




Figure 2 — Comparaison des 4 stratégies sur les 4 métriques clés

Le threshold tuning (seuil optimal = 0,30 au lieu de 0,5) permet le meilleur compromis Precision/Recall : contrairement au class_weight seul, qui privilégie la precision au détriment du recall (0,80), cette stratégie atteint 0,987 sur les deux à la fois.




Figure 3 — Recherche du seuil optimal (maximisation du F1-score)

Résultat final et diagnostic

Métrique (modèle retenu)	Valeur
ROC-AUC	0.9999 (seuil Excellent : > 0.95)
F1-score	0.987 (seuil Excellent : > 0.80)
Niveau atteint	Excellent (90-100 %)

Le modèle retenu — Random Forest entraîné avec SMOTE, seuil de décision optimisé à 0,30 — dépasse largement les deux seuils du barème (ROC-AUC et F1), avec seulement 2 faux négatifs et 2 faux positifs sur les 30 000 transactions de test.

Analyse coût-bénéfice (FP vs FN)

- Faux négatifs (fraudes ratées) : 2 cas → coût estimé 466 € (perte directe du montant fraudé).
- Faux positifs (clients légitimes bloqués) : 2 cas → coût estimé 30 € (friction / support client).
- Un faux négatif coûte en moyenne 16 fois plus cher qu'un faux positif : privilégier le recall est donc économiquement justifié pour la banque.

Interprétabilité (SHAP)

L'analyse SHAP identifie V1, V6, V4, V5 et V3 comme les variables les plus déterminantes dans la détection de fraude (features anonymisées par PCA, comme dans le dataset réel). Un rapport de risque a été généré pour 10 transactions frauduleuses, avec probabilité de fraude et niveau de risque catégorisé (CRITIQUE / ÉLEVÉ / MODÉRÉ / FAIBLE), livré dans shap_analysis.html et fraud_reports.csv.




Figure 4 — Impact des variables sur la prédiction de fraude (SHAP)

Limites et recommandations

- Dataset synthétique : le signal de fraude est ici volontairement marqué ; un vrai dataset (ex. Kaggle) présenterait davantage de chevauchement entre classes.

- Le seuil optimal (0,30) doit être recalibré périodiquement à mesure que les patterns de fraude évoluent.
- Recommandation : déployer le modèle avec le seuil optimisé, coupler à SHAP pour justifier chaque alerte auprès des équipes fraude, et prévoir un ré-entraînement régulier.